

高等数理统计

张鑫航

国防科技大学

版本：1.0

更新：2023 年 12 月 24 日



1 基本概念

1.1 统计结构

例 1.1 对一物理量进行测量，其真值 μ 未知，测量值为 x ，但测量有误差，故可认为

$$x = \mu + \varepsilon$$

$\{x_1, x_2, \dots, x_n\}$ 是测量值。

可加上一个假设，进一步设 $\varepsilon \sim N(0, \sigma^2)$ ，这就建立了一个统计结构。

定义 1.1 (统计结构) 设 $(\mathcal{X}, \mathcal{B})$ 为一可测空间， \mathcal{P} 为其上的一族概率分布，则成三元组 $(\mathcal{X}, \mathcal{B}, \mathcal{P})$ 为统计结构（模型）。若 \mathcal{P} 仅依赖于某参数（向量） θ ，即 $\mathcal{P} = \{\mathcal{P}_\theta : \theta \in \Theta\}$ ，就称为参数结构，否则成为非参数结构。

定义 1.2 (乘积结构与重复抽样结构) 设 $(\mathcal{X}, \mathcal{B}, \mathcal{P})$ 与 $(\mathcal{X}', \mathcal{B}', \mathcal{P}')$ 为两个统计结构，则称 $(\mathcal{X} \otimes \mathcal{X}', \mathcal{B} \otimes \mathcal{B}', \mathcal{P} \otimes \mathcal{P}')$ 为二者的乘积结构，记为 $(\mathcal{X}, \mathcal{B}, \mathcal{P}) \otimes (\mathcal{X}', \mathcal{B}', \mathcal{P}')$ ，特别的， n 个同样的统计结构的乘积称为重复抽样结构，记为 $(\mathcal{X}, \mathcal{B}, \mathcal{P})^n$ 或 $(\mathcal{X}^n, \mathcal{B}^n, \mathcal{P}^n)$ 。

定义 1.3 (样本分布函数) 设 $(\mathcal{X}, \mathcal{B}, \mathcal{P})^n$ 为一重复抽样结构， $\forall (X_1, X_2, \dots, X_n) \in X^n$ ，定义

$$F_n(x) = \frac{1}{n} \sum_{i=1}^n I_{(X_i \leq x)}$$

为经验分布函数（样本分布函数）。

定义 1.4 (所控) 设 u 和 v 是可测空间上 $(\mathcal{X}, \mathcal{B})$ 上的两个 σ -有限测度。若 $N \in \mathcal{B}$, $u(N) = 0 \Rightarrow v(N) = 0$, 则称 v 关于 u 绝对连续, 或 v 被 u 所控, 记为 $v \ll u$ 。

定义 1.5 (可控结构) 设 $(\mathcal{X}, \mathcal{B}, \mathcal{P})$ 为一统计结构, 若存在 u 为可测空间 $(\mathcal{X}, \mathcal{B})$ 上的 σ -有限测度, 使得 $\forall P \in \mathcal{P}$, $P \ll u$, 则称该结构为可控结构。进而 $p(x) = \frac{dP(x)}{du}$ 成为 p.r 密度。

1.2 常用分布族

1.2.1 Gamma 分布族

定义 1.6 (Gamma 分布族) 在 (R^+, \mathcal{B}_{R^+}) 上的密度函数形如

$$p(x; \alpha, \lambda) = \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda x} I_{(0, +\infty)}(x), \quad (\alpha > 0, \lambda > 0)$$

的分布称为参数为 α, λ 的 Gamma 分布族, 记为 $Ga(\alpha, \lambda)$ 。其中, $\Gamma(\alpha) = \int_0^{+\infty} x^{\alpha-1} e^{-x} dx$ 为 Gamma 函数。

注 因为 $\int_0^{+\infty} \lambda^\alpha x^{\alpha-1} e^{-\lambda x} dx = \int_0^{+\infty} (\lambda x)^{\alpha-1} e^{-\lambda x} d(\lambda x) = \Gamma(\alpha)$, 所以,

$$\int_{-\infty}^{+\infty} p(x; \alpha, \lambda) = \frac{\Gamma(\alpha)}{\Gamma(\alpha)} = 1$$

注 • 由图 1, α 影响 $Ga(\alpha, \lambda)$ 的形状, λ 影响 $Ga(\alpha, \lambda)$ 的尺寸

- $\alpha \leq 1$ 时, 严减; $1 < \alpha \leq 2$ 时, 先上凸, 后下凸; $\alpha > 2$ 时, 先下凸, 再上凸, 最后下凸, 两个拐点
- λ 影响密度函数的胖瘦

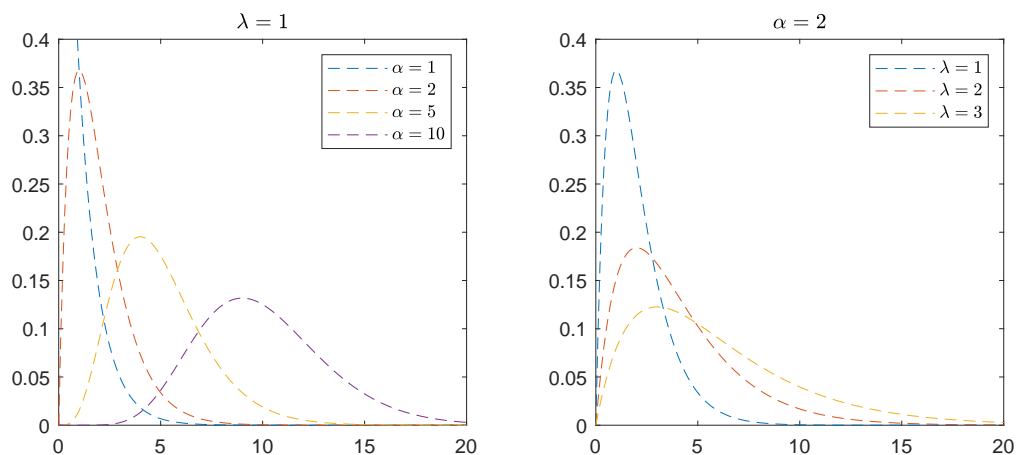


图 1: α 和 λ 对 $Ga(\alpha, \lambda)$ 的影响

设 $Z \sim Ga(\alpha, \lambda)$, 则其 k 阶矩

$$\begin{aligned}
 EZ^k &= \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha+k-1} e^{-\lambda x} dx \\
 &= \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)\lambda^k} \int_0^{+\infty} \frac{\lambda^{\alpha+k}}{\Gamma(\alpha+k)} x^{\alpha+k-1} e^{-\lambda x} dx \\
 &= \frac{\Gamma(\alpha+k)}{\Gamma(\alpha)\lambda^k} = \frac{(\alpha+k-1)(\alpha+k-2)\cdots\alpha}{\lambda^k}
 \end{aligned}$$

$Ga(\alpha, \lambda)$ 的特征函数

$$\begin{aligned} f(t) &= Ee^{ixt} = \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} x^{\alpha-1} e^{-\lambda(1-\frac{it}{\lambda})x} dx \\ &= (1 - \frac{it}{\lambda})^{-\alpha} \int_0^{+\infty} \frac{\lambda^\alpha}{\Gamma(\alpha)} [(1 - \frac{it}{\lambda})x]^{\alpha-1} e^{-\lambda(1-\frac{it}{\lambda})x} d(1 - \frac{it}{\lambda})x \\ &= (1 - \frac{it}{\lambda})^{-\alpha} \end{aligned}$$

于是, 设 $Z_1, Z_2, \dots, Z_n \sim Ga(\alpha, \lambda)$, 且 Z_i 相互独立, 则

$$Z_1 + Z_2 + \dots + Z_n \sim Ga(\alpha_1 + \alpha_2 + \dots + \alpha_n, \lambda)$$

两个特殊的 Gamma 分布

- 1) $Ga(1, \lambda) = Exp(\lambda)$, $p(x, \lambda) = \lambda e^{-\lambda x}$
- 2) $Ga(\frac{n}{2}, \frac{1}{2}) = \chi^2(n)$, $p(x, n) = \frac{1}{2^{n/2}\Gamma(n/2)} x^{n/2-1} e^{-x/2}, x > 0$

注 $Z \sim \chi^2(n)$, 则

$$\begin{aligned} EZ &= \frac{n/2}{1/2} = n \\ EZ^2 &= \frac{(n/2+1)(n/2)}{(1/2)^2} = n^2 + 2n \\ Var Z &= EZ^2 - (EZ)^2 = 2n \end{aligned}$$

例 1.2 电子产品的失效常常是由于外界的“冲击”引起。若在 $(0, t)$ 内发生冲击的次数 $N(t)$ 服从参数为 λt 的泊松分布, 试证明第 n 冲击到来的时间服从伽马分布 $Ga(n, \lambda)$

证明.

$$\begin{aligned}\{S_n \leq t\} &= \{N(t) \geq n\} \\ F_{S_n(t)} &= P\{S_n \leq t\} = P\{N(t) \geq n\} = \sum_{k=n}^{\infty} \frac{(\lambda t)^k}{k!} e^{-\lambda t} \\ F_{Ga(n,\lambda)}(t) &= \int_0^t \frac{\lambda^n}{\Gamma(n)} x^{n-1} e^{-\lambda x} dx \stackrel{?}{=} 1 - \sum_{k=0}^{n-1} \frac{(\lambda t)^k}{k!} e^{-\lambda t} = \sum_{k=n}^{\infty} \frac{(\lambda t)^k}{k!} e^{-\lambda t}\end{aligned}$$

1.2.2 Beta 分布族

定义 1.7 (Beta 分布) 设 $D = (0, 1)$, 定义在 (D, \mathcal{B}_D) , 密度函数形如 $p(x; a, b) = \frac{1}{B(a, b)} x^{a-1} (1-x)^{b-1} I_{(0,1)}(x)$, $(a > 0, b > 0)$ 的分布成为参数为 a, b 的 Beta 分布, 记为 $Be(a, b)$ 。其中 $B(a, b) = \int_0^1 x^{a-1} (1-x)^{b-1} dx = \frac{\Gamma(a)\Gamma(b)}{\Gamma(a+b)}$

- $a > 1$ 和 $b > 1$, $p(x)$ 单峰状, 在 $x = (a-1)/(a+b-2)$ 处达到最大值
- $a < 1$ 和 $b < 1$, $p(x)$ U 形, 在 $x = (a-1)/(a+b-2)$ 处达到最小值
- 当 $a = b + 1/2$ 时, Beta 分布为反正弦分布
- $a < 1$ 和 $b > 1$, $p(x)$ 严减
- $a > 1$ 和 $b < 1$, $p(x)$ 严增

注 设 $Z \sim Be(a, b)$, 则 Z 的 k 阶矩

$$\begin{aligned}
 EZ^k &= \int_0^1 \frac{1}{B(a, b)} x^{a+k-1} (1-x)^{b-1} dx \\
 &= \frac{B(a+k, b)}{B(a, b)} \int_0^1 \frac{1}{B(a+k, 1)} x^{a+k-1} (1-x)^{b-1} dx \\
 &= \frac{B(a+k, b)}{B(a, b)} = \frac{\Gamma(a+k)\Gamma(b)}{\Gamma(a+k+b)} \cdot \frac{\Gamma(a+b)}{\Gamma(a)\Gamma(b)} = \frac{\Gamma(a+k)\Gamma(a+b)}{\Gamma(a)\Gamma(a+k+b)} \\
 &= \frac{(a+k-1)(a+k-2)\cdots(a)}{(a+b+k-1)(a+b+k-2)\cdots(a+b)}
 \end{aligned}$$

特别的,

$$EZ = \frac{a}{a+b}, \quad EZ^2 = \frac{(a+1)a}{(a+b+1)(a+b)}, \quad \text{Var } Z = EZ^2 - (EZ)^2 = \left[\left(\frac{a+1}{a+b+1} \right)^2 - 1 \right] \left(\frac{a}{a+b} \right)^2$$

Beta 分布与 Gamma 分布的关系

设 $X_1 \sim \Gamma(\alpha_1, \lambda)$, $X_2 \sim \Gamma(\alpha_2, \lambda)$, 且相互独立, 则 $Y = \frac{X_1}{X_1 + X_2} \sim Be(\alpha_1, \alpha_2)$

证明. X_1 和 X_2 的联合分布为

$$p_{X_1, X_2}(x_1, x_2) = \frac{\lambda^{\alpha_1 + \alpha_2}}{\Gamma(\alpha_1)\Gamma(\alpha_2)} x_1^{\alpha_1-1} e^{-\lambda x_1} x_2^{\alpha_2-1} e^{-\lambda x_2}$$

令 $U = X_1$, $V = \frac{X_1}{X_1 + X_2}$, 则 $\begin{cases} X_1 = U \\ X_2 = U/V - U \end{cases}$, 且变换的行列式为

$$\begin{vmatrix} 1 & 0 \\ 1/v - 1 & -u/v^2 \end{vmatrix}$$

U, V 的联合分布为

$$\begin{aligned} p_{U,V}(u, v) &= p_{X_1, X_2}(u, v) |J| \\ &= \frac{\lambda^{\alpha_1 + \alpha_2}}{\Gamma(\alpha_1) \Gamma(\alpha_2)} u^{\alpha_1 - 1} e^{-\lambda u} \left(\frac{u}{v} - u\right)^{\alpha_2 - 1} e^{-\lambda(u/v - u)} \frac{u}{v^2} \end{aligned}$$

则 V 的边缘分布为

$$p_V(v) = \int_0^\infty p_{U,V}(u, v) du = \frac{\Gamma(\alpha_1 + \alpha_2)}{\Gamma(\alpha_1) \Gamma(\alpha_2)} v^{\alpha_1 - 1} (1 - v)^{\alpha_2 - 1}$$

即 $Y_2 \sim Be(\alpha_1, \alpha_2)$

Beta-Binomial 共轭性

证明. 假定二项分布 $b(n, p)$ 的参数 p 服从 $Be(a, b)$ 的先验分布。然后又做了 $n_1 + n_2$ 次伯努利试验

(记为 W) 成功 n_1 次, 失败 n_2 次, 于是后验分布

$$\begin{aligned}
 P(p|W) &= \frac{P(p, W)}{P(W)} = \frac{P(W|p)P(p)}{\int_0^1 P(W|p)P(p)dp} \\
 &= \frac{C_{n_1+n_2}^{n_1} p^{n_1} (1-p)^{n_2} \frac{1}{B(a,b)} p^{a-1} (1-p)^{b-1}}{\int_0^1 C_{n_1+n_2}^{n_1} p^{n_1} (1-p)^{n_2} \frac{1}{B(a,b)} p^{a-1} (1-p)^{b-1} dp} = \frac{p^{n_1+a-1} (1-p)^{n_2+b-1}}{\int_0^1 p^{n_1+a-1} (1-p)^{n_2+b-1} dp} \\
 &= \frac{p^{n_1+a-1} (1-p)^{n_2+b-1}}{B(n_1+a-1, n_2+b-1)}
 \end{aligned}$$

p 的后验分布为 $Be(n_1 + a, n_2 + b)$, $Be(a, b) + \text{BinomCount}(n_1, n_2) = Be(n_1 + a, n_2 + b)$ 。

1.2.3 Fisher 分布族

定义 1.8 (Fisher Z 分布) 定义在 (R^+, \mathcal{B}_{R^+}) 上的密度函数形如

$$p(x; a, b) = \frac{1}{B(a, b)} \frac{x^{a-1}}{(1+x)^{a+b}} I_{(0,+\infty)}(x), \quad (a > 0, b > 0)$$

的分布承诺为参数为 a, b 的 Fisher Z 分布, 记作 $Z(a, b)$ 。

设 $Z \sim Z(a, b)$, 则 Z 的 k 阶矩

$$\begin{aligned} EZ^k &= \int_0^\infty \frac{1}{B(a, b)} \frac{x^{a+k-1}}{(1+x)^{a+b}} dx \\ &= \frac{B(a+k, b-k)}{B(a+b)} \int_0^\infty \frac{1}{B(a+k, b-k)} \frac{x^{a+k-1}}{(1+x)^{a+b}} dx \\ &= \frac{B(a+k, b-k)}{B(a+b)} \end{aligned}$$

特别的

$$EZ = \frac{a}{b-1}, b > 1; \quad EZ^2 = \frac{(a+1)a}{(b-1)(b-2)}, b > 2$$

Fisher 分布与 Beta 分布的关系

若 $Z \sim Be(a, b)$, 则 $Y = \frac{Z}{1-Z} \sim Z(a, b)$

证明. 有 $Z = \frac{Y}{1+Y}$, 那么, $|\frac{dz}{dy}| = (\frac{1}{1+y})^2$ 因此

$$\begin{aligned} f_Y(y) &= f_Z\left(\frac{y}{1+y}\right) \left|\frac{dz}{dy}\right| \\ &= \frac{1}{B(a, b)} \left(\frac{y}{1+y}\right)^{a-1} \left(\frac{1}{1+y}\right)^{b-1} \left(\frac{1}{1+y}\right)^2 \\ &= \frac{1}{B(a, b)} \frac{y^{a-1}}{(1+y)^{a+b}} \end{aligned}$$

若 $Z \sim Z(a, b)$, 则 $Y = \frac{Z}{1+Z} \sim Be(a, b)$

证明. 有 $Z = \frac{Y}{1-Y}$, 那么, $|\frac{dz}{dy}| = (\frac{1}{1-y})^2$ 因此

$$\begin{aligned} f_Y(y) &= f_Z\left(\frac{y}{1-y}\right) \left|\frac{dz}{dy}\right| \\ &= \frac{1}{B(a, b)} \frac{\left(\frac{y}{1-y}\right)^{a-1}}{\left(1 + \frac{y}{1-y}\right)^{a+b}} \left(\frac{1}{1-y}\right)^2 \\ &= \frac{1}{B(a, b)} y^{a-1} (1-y)^{b-1} \end{aligned}$$

Fisher 分布与 Gamma 分布的关系

设 $X_1 \sim \Gamma(\alpha_1, \lambda)$, $X_2 \sim (\alpha_2, \lambda)$, 且相互独立, 则

$$Y = X_1/X_2 \sim Z(\alpha_1, \alpha_2)$$

证明. 设 $\begin{cases} U = X_1 \\ V = X_1/X_2 \end{cases}$, 有 $\begin{cases} X_1 = U \\ X_2 = U/V \end{cases}$ 且变换的行列式为

$$J = \begin{vmatrix} 1 & 0 \\ 1/V & -U/V^2 \end{vmatrix}$$

U, V 的联合分布为

$$\begin{aligned} p_{U,V}(u, v) &= p_{X,Y}(u, v) |J| \\ &= \frac{\frac{\lambda^{\alpha_1}}{\Gamma(\alpha_1)} u^{\alpha_1-1} e^{-\lambda u}}{\frac{\lambda^{\alpha_2}}{\Gamma(\alpha_2)} (u/v)^{\alpha_2-1} e^{-\lambda u/v}} \frac{u}{v^2} \end{aligned}$$

V 的边缘分布为

$$\begin{aligned} p_V(v) &= \int_0^{+\infty} p_{U,V}(u, v) du \\ &= \frac{\Gamma(\alpha_1 + \alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \frac{v^{\alpha_1-1}}{(1+v)^{\alpha_1+\alpha_2}} \int_0^{+\infty} \frac{1}{\Gamma(\alpha_1 + \alpha_2)} \left(\frac{\lambda(1+v)}{v} \right)^{\alpha_1+\alpha_2} u^{\alpha_1+\alpha_2-1} e^{-\lambda \frac{1+v}{v} u} du \\ &= \frac{\Gamma(\alpha_1 + \alpha_2)}{\Gamma(\alpha_1)\Gamma(\alpha_2)} \frac{v^{\alpha_1-1}}{(1+v)^{\alpha_1+\alpha_2}} \end{aligned}$$

1.2.4 t 分布族

定义 1.9 (t 分布族) 在 (R, \mathcal{B}_R) 上的密度函数形如

$$p(x; \alpha) = \frac{\Gamma(\frac{\alpha+1}{2})}{\sqrt{\alpha\pi}\Gamma(\frac{\alpha}{2})} \left(1 + \frac{x^2}{\alpha}\right)^{-\frac{\alpha+1}{2}}$$

的分布族称作自由度为 α 的 t 分布族, 记为 $t(\alpha)$

注 1° 设 $X \sim t(\alpha)$, 则由于其分布函数为偶函数, 则 Z 的 k 阶矩为

$$\begin{aligned} E^{2k+1} &= 0, & \alpha > 2k+1 \\ E^{2k} &= \frac{\alpha^k}{\sqrt{\pi}} \frac{\Gamma(\frac{\alpha}{2} - k) \Gamma(k + \frac{1}{2})}{\Gamma(\frac{\alpha}{2})} & \alpha > 2k \end{aligned}$$

2° t 分布于标准正态分布的关系

$$\begin{aligned} \lim_{\alpha \rightarrow \infty} \frac{\Gamma(\frac{\alpha+1}{2})}{\sqrt{\alpha\pi} \Gamma(\frac{\alpha}{2})} &= \frac{1}{2} \\ \lim_{\alpha \rightarrow \infty} (1 + \frac{x^2}{\alpha})^{-\frac{\alpha+1}{2}} &= \lim_{\alpha \rightarrow \infty} [(1 + \frac{x^2}{\alpha})^{\frac{\alpha}{2}}]^{-\frac{x^2}{\alpha} \cdot \frac{\alpha+1}{2}} = e^{-\frac{x^2}{2}} \end{aligned}$$

3° 考虑 Cauchy 分布 $X \sim t(1)$ 的 k 阶矩 $k \geq 1$

$$\begin{aligned} E|X|^k &= \int_{-\infty}^{\infty} |x|^k \cdot \frac{1}{\pi(1+x^2)} dx = \int_0^{\infty} x^{k-1} \cdot \frac{2x}{\pi(1+x^2)} dx \\ &= \int_0^{\infty} \frac{x^{k-1}}{\pi} d[\ln(1+x^2)] = \frac{x^{k-1} \ln(1+x^2)}{\pi} \Big|_0^{\infty} - \frac{k-1}{\pi} \int_0^{\infty} \ln(1+x^2) x^{k-2} dx \end{aligned}$$

$$k \geq 2, \lim_{x \rightarrow \infty} \frac{x^k}{\pi(1+x^2)} = \infty, \text{ 不存在。}$$

1.2.5 多元正态分布族

1° 已知一元标准正态分布 $N(0,1)$ 的随机变量为 U , 也即

$$U \sim \phi(u) = \frac{1}{\sqrt{2\pi}} e^{-u^2/2}, u \in R$$

对于任意的 $\mu \in R, \sigma > 0$, 易有

$$X = \mu + \sigma U \sim p(x) = \frac{1}{\sqrt{2\pi}\sigma} e^{-\frac{(x-\mu)^2}{2\sigma^2}}$$

$$X \sim N(\mu, \sigma^2)$$

2° 设 $U = (u_1, u_2, \dots, u_n)$ 满足 $u_i \sim N(0, 1), i = 1, 2, \dots, n$, 且相互独立, 则

$$U \sim p(u) = \frac{1}{(\sqrt{2\pi})^n} e^{-\frac{1}{2}u^T u}$$

且 $E(U) = 0, U = I_n$, 称 U 为 n 元标准正态分布, 记为 $U \sim N_n(0, I_n)$ 。

3° 设 $\mu = (\mu_1, \mu_2, \dots, \mu_n)^T$ 是常数向量, Σ 是一个 n 阶正定矩阵, 则经特征值分解有 $\Sigma = AA^T$, 于是 $\Sigma^{-1} = (A^T)^{-1}A^{-1}$, $|\Sigma|^{-\frac{1}{2}} = |A|^{-1}$ 。令 $X = \mu + AU$ 则可以算出

$$X \sim p(x) = \frac{1}{(\sqrt{2\pi})^n} |\Sigma|^{-\frac{1}{2}} e^{-\frac{1}{2}(x-\mu)^T \Sigma^{-1}(x-\mu)}, X \in R^n$$

此时, $E(X) = \mu$, $\text{Var}(X) = \Sigma$, 称 X 服从多元正态分布, 记为 $X \sim N_n(\mu, \Sigma)$ 。

若 A 不是满秩的, 定义多元正态分布 $X = \mu + AU$

4° 考虑 X 的特征函数

$$f_X(t) = Ee^{it^T x} = e^{it^T \mu} Ee^{it^T AU}$$

令 $\mathbf{t}^T \mathbf{A} = \mathbf{a}^T = (a_1 \ a_2 \ \cdots \ a_n)$ 于是后验分布

$$\begin{aligned} f_{AU}(\mathbf{t}) &= E e^{i\mathbf{t}^T \mathbf{A} U} = \prod_{i=1}^n E e^{i a_i U_i} = \prod_{i=1}^n f_{U_i}(a_i) = \prod_{i=1}^n e^{-\frac{1}{2} a_i^2} \\ &= e^{-\frac{1}{2} \mathbf{a}^T \mathbf{a}} = e^{-\frac{1}{2} \mathbf{t}^T \mathbf{A} \mathbf{A}^T \mathbf{t}} = e^{-\frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t}} \end{aligned}$$

所以 $f_X(t) = \exp(i\mathbf{t}^T \boldsymbol{\mu} - \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t})$, 与 \mathbf{A} 满秩时一致。

定义 1.10 (n 元正态分布) 设 $\mathbf{X} = (X_1 \ X_2 \ \cdots \ X_n)$ 是一个 n 维随机向量, 且 $E\mathbf{X} = \boldsymbol{\mu}$, $\text{Var } \mathbf{X} = \boldsymbol{\Sigma}$ (**非负定**), 若其特征函数为 $f_X(t) = \exp(i\mathbf{t}^T \boldsymbol{\mu} - \frac{1}{2} \mathbf{t}^T \boldsymbol{\Sigma} \mathbf{t})$, 则称 \mathbf{X} 为 n 元正态分布, 记为 $X \sim N_n(\boldsymbol{\mu}, \boldsymbol{\Sigma})$, 而矩阵 $\boldsymbol{\Sigma}$ 的秩 $\text{rank}(\boldsymbol{\Sigma}) = r$ 称为这个分布的秩。

注 若 $\text{rank}(\boldsymbol{\Sigma}) = n$, $\boldsymbol{\Sigma}^{-1}$ 存在, \mathbf{X} 具有非奇的 n 元正态分布, 密度函数为

$$\mathbf{X} \sim p(\mathbf{x}) = \frac{1}{(\sqrt{2\pi})^n} |\boldsymbol{\Sigma}|^{-\frac{1}{2}} e^{-\frac{1}{2}(\mathbf{x}-\boldsymbol{\mu})^T \boldsymbol{\Sigma}^{-1}(\mathbf{x}-\boldsymbol{\mu})}, \quad \mathbf{X} \in \mathbf{R}^n$$

若 $\text{rank}(\boldsymbol{\Sigma}) = r < n$, $\boldsymbol{\Sigma}^{-1}$ 不存在, 则其**密度函数形式又该如何?**

定义 1.11 (多元正态分布) 设 $\mathbf{X} = (X_1 \ X_2 \ \cdots \ X_n)^T$ 是一个 n 维随机向量, 若 \mathbf{X} 与 $\boldsymbol{\mu} + \mathbf{B}U$ 具有相同的分布, 其中 $\boldsymbol{\mu}$ 为 n 维向量, \mathbf{B} 是一个秩为 r 的 $n \times r$ 阶矩阵, $U \sim N_r(0, \mathbf{I}_r)$, 那么称 $\mathbf{X} \sim N_n(\boldsymbol{\mu}, \mathbf{B}\mathbf{B}^T)$

1.3 统计量及其分布

1.3.1 统计量的概念

定义 1.12 (统计量) 设 $(\mathcal{X}, \mathcal{B}, \mathcal{P})$ 是一个统计结构, $(\mathcal{T}, \mathcal{C})$ 是一个可测空间, 若 $T: \mathcal{X} \rightarrow \mathcal{T}$ 是一个可测映射, 且与 P 无关, 则称 T 是此结构的统计量。

对定义的理解:

注 1° T 是可测映射, 即 σ 代数 \mathcal{C} 中任一元素 (集合) C 的原像 $T^{-1}(C) = \{x: T(x) \in C\}$ 是 σ 代数 \mathcal{B} 中的元素 (集合)。

2° T 与 P 无关, 即不含未知参数

3° T 可以是向量, $T(X) = (T(X_1) \ T(X_2) \ \cdots \ T(X_k))$, 也可以是一维的。统计量 T 的值域 T 一般常用 R 或者 R^k 。

1.3.2 统计量的分布 (抽样分布)

定义 1.13 (抽样分布) 统计量的概率分布, 称为抽样分布, 也成为诱导分布。

设 $T: (\mathbf{X}, \mathbf{B}) \rightarrow (\mathbf{T}, \mathbf{C})$, 对任意 $C \in \mathbf{C}$, 概率

$$P^T = P(T(x) \in C) = \int_{x: T(x) \in C} dP = \int_{T^{-1}(C)} dP = P(T^{-1}(C))$$

其中 $P \in \mathbf{P}$, 称 P^T 是 P 的诱导测度, $P^T = \{P^T: P \in \mathbf{P}\}$ 成为诱导分布族, 而 (Y, C, P^T) 称为 T 的诱导结构。

注 若 $(\mathbf{X}, \mathbf{B}, \mathbf{P})$ 是可控结构, 则诱导结构 $(\mathbf{T}, \mathbf{C}, \mathbf{P}^T)$ 也是可控结构。

证明. 因为 $(\mathbf{X}, \mathbf{B}, \mathbf{P})$ 是可控结构, 则存在 σ 有限测度 μ , 使 $P \ll \mu \quad (\forall P \text{ in } \mathbf{P})$, 令 $\mu^T(C) = \mu(T^{-1}(C)), \forall C \in \mathbf{C}$ 。

若有 μ^T 的零测集 $N, \mu^T(C) = \mu(T^{-1}(C)) = 0$, 因为 $\forall P \in \mathbf{P}, \mathbf{P} \ll \mu$, 则 $P^T(N) = P(T^{-1}(N)) = 0$, 从而 $P^T \ll \mu^T$

1° 设 $T = T(X_1, X_2, \dots, X_n)$ 且为可微函数, 其梯度的模为正, 即

$$\|\text{grad } T(x_1, x_2, \dots, x_n)\| = \sqrt{\sum_{i=1}^n \left[\frac{\partial}{\partial x_i} T(x_1, x_2, \dots, x_n) \right]^2} > 0$$

则此时 T 的分布函数为

$$F_T(t) = P\{T(x_1, \dots, x_n) \leq t\} = \int_D^{n\text{重}} \cdots \int p(x_1, x_2, \dots, x_n) dx_1 \cdots dx_n$$

其中 $D = \{(x_1, x_2, \dots, x_n) : T(x_1, x_2, \dots, x_n) \leq t\}$ 。可以计算出其密度函数为

$$p_T(t) = \int_{S_{n-1}}^{n-1\text{重}} \cdots \int p(x_1, x_2, \dots, x_n) \frac{dS_{n-1}}{\|\text{grad } T(x_1, x_2, \dots, x_n)\|}$$

其中积分域是由方程 $T(x_1, x_2, \dots, x_n) = t$ 所决定的 $n-1$ 维曲面 S_{n-1}

2° T 是 k 维统计量 ($k < n$)

$$p_T(t) = \int_{S_{n-k}}^{n-k \text{重}} \cdots \int \frac{p(x_1, \cdots, x_n)}{\left(\sum_{i_1 < \cdots < i_n} \left[\frac{D(T_1, \cdots, T_k)}{D(x_{i_1}, \cdots, x_{i_k})} \right]^2 \right)^{\frac{1}{2}}} dS_{n-k}$$

其中积分域是由 k 个方程 $T_j(x_1, \cdots, x_n) = t_j, j = 1, \cdots, k$ 所决定的 $n - k$ 维曲面 S_{n-k} , 而

$$\frac{D(T_1, \cdots, T_k)}{D(x_{i_1}, \cdots, x_{i_k})} = \left| \begin{pmatrix} \frac{\partial T_1}{\partial x_{i_1}} & \cdots & \frac{\partial T_1}{\partial x_{i_k}} \\ \vdots & \vdots & \vdots \\ \frac{\partial T_k}{\partial x_{i_1}} & \cdots & \frac{\partial T_k}{\partial x_{i_k}} \end{pmatrix} \right|$$

是函数 T_1, \cdots, T_k 对变量 x_{i_1}, \cdots, x_{i_k} 的雅可比行列式。

1.3.3 次序统计量及其分布

定义 1.14 (次序统计量) 设 X_1, \cdots, X_n 是来自某总体的一个样本, 将其按从小到大的次序排列成 $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$, 称 $(X_{(1)} \ X_{(2)} \ \cdots \ X_{(n)})$ 为该样本的次序统计量。 $X_{(1)}$ 称为该样本的最小次序统计量, $X_{(n)}$ 称为样本的最大次序统计量。

“概率元方法” (p.r.) 元法的引入

把 $X_{(1)} \leq X_{(2)} \leq \cdots \leq X_{(n)}$ 的观察值记为 $y_1 \leq y_2 \leq \cdots \leq y_n$, 设总体 X 的密度函数为 $p(x)$, 则连续随机变量落在很小区间 $(x, x + dx)$ 的概率为

$$P(x < X < x + dx) = p(x)dx + x(dx)$$

$p(x)dx$ 称为 X 的概率元；反正，若存在函数 $p(x)$ 使上式成立，则 $p(x)$ 就是 X 的密度函数。

次序统计量的分布

区间 $(-\infty, y_k), [y_k, y_k + dy_k), [y_k, +\infty)$

$X_{(k)}$ 的概率函数 $g(y_k)$ ，其中 $1 \leq k \leq n$

$$g(y_k)dy_k = \frac{n!}{(k-1)!(n-k)!} [F(y_k)]^{k-1} p(y_k) dy_k [1 - F(y_k + dy_k)]^{n-k}$$

两边约去 dy_k 后，再让 $dy_k \rightarrow 0$

$$g(y_k) = \frac{n!}{(k-1)!(n-k)!} [F(y_k)]^{k-1} [1 - F(y_k)]^{n-k} p(y_k)$$

最小次序统计量 $g(y_1) = n[1 - F(y_1)]^{n-1} p(y_1)$

最大次序统计量 $g(y_n) = n[F(y_n)]^{n-1} p(y_n)$

例 1.3 【猜数游戏】 一个魔盒上面有一个按钮，每按下按钮，就均匀地输出一个 $[0, 1]$ 之间的随机数，甲按 10 下得到 10 个数，要乙猜第 7 大的数是什么，偏离不超过 0.01 就算对。乙应该怎么猜呢？

- $X_1, X_2, \dots, X_n \stackrel{\text{iid}}{\sim} U(0, 1)$
- 把这 n 个随机变量排序后得到顺序统计量 $X_{(1)}, X_{(2)}, \dots, X_{(n)}$
- $F(y) = y, p(y) = 1$

$X_{(7)}$ 的分布 $g(y_7)$ 为

$$\begin{aligned} g(y_7) &= \frac{10!}{(7-1)!(10-7)!} y_7^{7-1} (1-y_7)^{10-7} \times 1 \\ &= \frac{10!}{6!3!} y_7^6 (1-y_7)^3 \end{aligned}$$

$X_{(7)} \sim Be(7, 4)$, 在 $y = \frac{7-1}{7+4-2} = \frac{2}{3}$ 时, 概率最大。

例 1.4 设 X_1, \dots, X_n 是来自均匀分布 $U(0, 1)$ 的一个样本, 要求该样本第 k 个次序统计量 $X_{(k)}$ 的分布与期望

$$g(y_k) = \frac{n!}{(k-1)!(n-k)!} y_k^{k-1} (1-y_k)^{n-k},$$

可以知道 $X_{(k)} \sim Be(k, n-k+1)$, 期望为 $E(X_{(k)}) = \frac{k}{n+1}$

$X_{(k)}$ 与 $X_{(j)}$ 的联合密度函数 $g(y_k, y_j)$, 其中 $1 \leq k < j \leq n$

区间 $(-\infty, y_k)$, $[y_k, y_k + dy_k)$, $[y_k + dy_k, y_j)$, $[y_j, y_j + dy_j)$, $[y_j + dy_j, +\infty)$

$$\begin{aligned} g(y_k, y_j) dy_k dy_j &= \frac{n!}{(k-1)!(j-1-k)(n-j)!} [F(y_k)]^{k-1} p(y_k) dy_k \times \\ &\quad [F(y_j) - F(y_k + dy_k)]^{j-1-k} p(y_j) dy_j [1 - F(y_j + dy_j)]^{n-j} \end{aligned}$$

两边约去 dy_k, dy_j 后, 再让 $dy_k \rightarrow 0, dy_j \rightarrow 0$

$$g(y_k, y_j) = \frac{n!}{(k-1)!(j-1-k)!(n-j)!} [F(y_k)]^{k-1} \times \\ [F(y_j) - F(y_k)]^{j-1-k} [1 - F(y_j)]^{n-j} p(y_k) p(y_j)$$

最小次序统计量与最大次序统计量的联合密度

$$g(y_1, y_n) = n(n-1)[F(y_n) - F(y_1)]^{n-2} p(y_1) p(y_n), \quad y_1 \leq y_n$$

前 r 个次序统计量 $X_{(1)}, X_{(2)}, \dots, X_{(r)}$ 的联合密度函数

$$g(y_1, \dots, y_r) = \frac{n!}{(n-r)!} [1 - F(y_r)]^{n-r} \cdot p(y_1) \cdots p(y_r), \quad y_1 \leq \dots \leq y_n$$

次序统计量的矩的存在性问题

定理 1.1 设 X_1, \dots, X_n 是来自于某总体 X 的一个样本, 且对某个 $a > 0$ 有 $E|X|^a < \infty$ 。则当 n, k 和 r 满足

$$r \leq a \cdot \min(k, n - k + 1)$$

有 $E|X_{(k)}|^r < \infty$, 其中 $X_{(k)}$ 为该样本的第 k 个次序统计量。

证明. 要证明 $E|X_{(k)}|^r < \infty$, 根据定义, 会用到 $\int_{-\infty}^0 |x|^r dG_k(x) + \int_0^{\infty} x^r dG_k(x)$ 的值必须有界。而 $G_k(x)$ 与总体分布 $F(x)$ 有关, 故要转化

证明分三步:

1° 证明: $|x|^a[1 - F(x)]$ 有界

2° 证明: $|x|^a[F(x)]$ 有界

3° $X_{(k)}$ 代入计算 $E|X_{(k)}|^r$ 积分的值

$$\begin{aligned}\infty > E|X|^a &= \int_{-\infty}^{+\infty} |x|^a dP\{|X| \leq x\} \geq \int_{|x|}^{+\infty} |x|^a dP\{|X| \leq x\} \\ &\geq |x|^a \int_{|x|}^{+\infty} dP\{|X| \leq t\} = |x|^a P\{|X| \geq t\} \\ &= |x|^a \{[1 - F(x)] + [F(-x)]\}\end{aligned}$$

对于

$$\int_{|x|}^{+\infty} |x|^a dP\{|X| \leq x\} \geq |x|^a \{[1 - F(x)] + [F(-x)]\}$$

= 两边让 $x \rightarrow +\infty$ 有

$$0 = \lim_{x \rightarrow \infty} \int_{|x|}^{+\infty} |x|^a dP\{|X| \leq x\} \geq \lim_{x \rightarrow +\infty} |x|^a [1 - F(x)] + \lim_{x \rightarrow +\infty} |x|^a [F(-x)] \geq 0$$

综上所述 $\lim_{x \rightarrow +\infty} |x|^a [1 - F(x)] = 0$, $\lim_{x \rightarrow +\infty} |x|^a [F(-x)] = 0$

$$\begin{aligned}
E|X_{(k)}|^r &= \int_{-\infty}^0 |x|^r \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} p(x) dx + \\
&\quad \int_0^{+\infty} |x|^r \frac{n!}{(k-1)!(n-k)!} [F(x)]^{k-1} [1-F(x)]^{n-k} p(x) dx \\
&= \frac{n!}{(k-1)!(n-k)!} [(1) + (2)]
\end{aligned}$$

考虑 (1) $< \infty$

$$\begin{aligned}
(1) &= \int_{-\infty}^0 |x|^r [F(x)]^{k-1} [1-F(x)]^{n-k} p(x) dx \\
&= \int_{-\infty}^0 \{|x|^a [F(x)]\}^{\frac{r-a}{a}} [F(x)]^{k-1-\frac{r-a}{a}} [1-F(x)]^{n-k} x^a p(x) dx
\end{aligned}$$

需要

$$k-1-\frac{r-a}{a} > 0 \rightarrow r < ak$$

考虑 (2) $< \infty$

$$\begin{aligned}
(2) &= \int_0^{+\infty} |x|^r [F(x)]^{k-1} [1-F(x)]^{n-k} p(x) dx \\
&= \int_0^{+\infty} \{|x|^a [1-F(x)]\}^{\frac{r-a}{a}} [1-F(x)]^{n-k-\frac{r-a}{a}} [F(x)]^{k-1} x^a p(x) dx
\end{aligned}$$

需要

$$n-k-\frac{r-a}{a} > 0 \rightarrow r < a(n-k+1)$$

综上, $r \leq a \cdot \min(k, n-k+1)$

例 1.5 设随机变量 X 服从 Cauchy 分布，其密度函数为

$$p(x) = \frac{1}{\pi(1+x^2)}, \quad x \in R$$

请考虑总体的 k 阶矩和次序统计量的 k 阶矩为：

因为 X 服从 Cauchy 分布，则 $E|X|^r = \infty, \forall r \leq 1$ ，然而对于任意小 $\varepsilon > 0$ ，有

$$\begin{aligned} E|X|^{1-\varepsilon} &= \int_{-\infty}^{\infty} |x|^{1-\varepsilon} \cdot \frac{1}{\pi(1+x^2)} dx = \int_0^{\infty} x^{-\varepsilon} \cdot \frac{2x}{\pi(1+x^2)} dx \\ &= \int_0^{\infty} \frac{x^{-\varepsilon}}{\pi} d[\ln(1+x^2)] = \frac{\ln(1+x^2)}{\pi x^{\varepsilon}} \Bigg|_0^{\infty} + \frac{\varepsilon}{\pi} \int_0^{\infty} \ln(1+x^2) x^{-\varepsilon-1} dx \\ &= 0 + \frac{\varepsilon}{\pi} \int_0^{\infty} x^{-1-\varepsilon/2} \frac{\ln(1+x^2)}{x^{\varepsilon/2}} dx \end{aligned}$$

由于 $\lim_{x \rightarrow \infty} \frac{\ln(1+x^2)}{x^{\varepsilon/2}} = 0$ ，故存在 $x_0 > 0, M > 0$ ，使得当 $x > x_0$ 时， $\frac{\ln(1+x^2)}{x^{\varepsilon/2}} < M$ ，从而

$$\begin{aligned} E|X|^{1-\varepsilon} &= \frac{\varepsilon}{\pi} \int_0^{\infty} x^{-1-\varepsilon/2} \frac{\ln(1+x^2)}{x^{\varepsilon/2}} dx \\ &\leq \frac{\varepsilon}{\pi} \left[\int_0^{x_0} x^{-1-\varepsilon} \ln(1+x^2) dx + M \int_{x_0}^{\infty} x^{-1-\varepsilon/2} dx \right] < \infty \end{aligned}$$

这表明：Cauchy 随机变量的 $1-\varepsilon$ 阶矩存在，其中 $\varepsilon > 0$ 可以任意小。

评论

1.4 统计量的近似分布

1.4.1 随机变量序列的两种收敛性

定义 1.15 (依概率收敛) 设 $\{Z_n\}$ 为一随机变量序列, Z 为另一随机变量, 若 $\forall \varepsilon > 0$, 有 $P\{|Z_n - Z| > \varepsilon\} \rightarrow 0, n \rightarrow \infty$, 则称随机变量序列 $\{Z_n\}$ **依概率收敛** 于 Z , 记为 $Z_n \xrightarrow{P} Z$.

定义 1.16 (依分布收敛) 设 $\{Z_n\}$ 为一随机变量序列, Z 为另一随机变量, 又 $F_n(x)$ 与 $F(x)$ 分别是 $\{Z_n\}$ 和 Z 的分布函数, 若对 $F(x)$ 的每个连续点 x 有 $F_n(x) \rightarrow F(x), n \rightarrow \infty$, 则称随机变量序列 $\{Z_n\}$ **依分布收敛** 于 Z , 记为 $Z_n \xrightarrow{L} Z$.

定理 1.2 设 $Z_n \xrightarrow{P} Z$, 则 $Z_n \xrightarrow{L} Z$.

证明. 对于 $\forall x, x' (x' < x)$, 由于

$$\begin{aligned}\{Z < x'\} &= \{Z_n < x, Z < x'\} \cup \{Z_n \geq x, Z < x'\} \\ &\subset \{Z_n < x\} \cup \{Z_n \geq x, Z < x'\}\end{aligned}$$

因而有

$$F(x') \leq F_n(x) + P\{Z_n \geq x, Z < x'\}$$

另一方面, 有 $Z_n \xrightarrow{P} Z$, 当 $n \rightarrow \infty$

$$P\{Z_n \geq x, Z < x'\} \leq P\{|Z_n - Z| \geq x - x'\} \rightarrow 0$$

故而 $F(x') \leq \liminf_{n \rightarrow \infty} F_n(x)$ 。

同理, $\forall x, x'' (x'' > x)$, 由于

$$\begin{aligned}\{Z_n < x\} &= \{Z < x'', Z_n < x\} \cup \{Z \geq x'', Z_n < x\} \\ &\subset \{Z < x''\} \cup \{Z_n \geq x, Z < x'\}\end{aligned}$$

因而有

$$F(x'') \geq F_n(x) - P\{Z_n \geq x, Z < x''\}$$

另一方面, 有 $Z_n \xrightarrow{p} Z$, 当 $n \rightarrow \infty$

$$P\{Z < x'', Z_n \geq x\} \geq P\{|Z - Z_n| \geq x'' - x\} \rightarrow 0$$

故而

$$F(x'') \geq \limsup_{n \rightarrow \infty} F_n(x),$$

所以, $\forall x' < x < x''$, 有

$$F(x') \leq \liminf_{n \rightarrow \infty} F_n(x) \leq \limsup_{n \rightarrow \infty} F_n(x) \leq F(x'')$$

当 x 是 $F(x)$ 的连续点, 令 $x' \rightarrow x, x'' \rightarrow x$, 则有

$$\lim_{n \rightarrow \infty} F_n(x) = F(x),$$

即 $Z_n \xrightarrow{L} Z$

定理 1.3 设 c 为常数, 若 $Z_n \xrightarrow{L} c$, 则 $Z_n \xrightarrow{P} c$

证明. 对 $\forall \varepsilon > 0$, 有

$$\begin{aligned} P\{|Z_n - c| \geq \varepsilon\} &= P\{Z_n - c \geq \varepsilon\} + P\{Z_n - c \leq -\varepsilon\} \\ &= 1 - P\{Z_n < c + \varepsilon\} + P\{Z_n \leq c - \varepsilon\} \leq 1 - F_n(c + \frac{\varepsilon}{2}) + F_n(c - \varepsilon) \\ &\rightarrow 1 - F(c + \frac{\varepsilon}{2}) + F(c - \varepsilon) = 1 - 1 + 0 = 0 \quad (n \rightarrow \infty) \end{aligned}$$

定理 1.4 (Slutsky 定理) 设 $\{Z_n\}$ 和 $\{U_n\}$ 是两个随机变量序列, 若 $Z_n \xrightarrow{L} Z$, $U_n \xrightarrow{P} c$ (常数), 则有

$$\begin{aligned} \text{a)} \quad & Z_n + U_n \xrightarrow{L} Z + c \\ \text{b)} \quad & Z_n U_n \xrightarrow{L} Zc \\ \text{c)} \quad & Z_n / U_n \xrightarrow{L} Z/c \quad (c \neq 0) \end{aligned}$$

证明. a) 一方面

$$\begin{aligned} &P\{Z_n + U_n \leq x\} \\ &= P\{Z_n + U_n \leq x, |U_n - c| \leq \varepsilon\} + P\{Z_n + U_n \leq x, |U_n - c| > \varepsilon\} \\ &\leq P\{Z_n \leq x - c + \varepsilon, |U_n - c| \leq \varepsilon\} + P\{|U_n - c| > \varepsilon\} \\ &\leq P\{Z_n \leq x - c + \varepsilon\} + P\{|U_n - c| > \varepsilon\} \end{aligned}$$

因此

$$\begin{aligned} & \lim_{n \rightarrow \infty} \sup P\{Z_n + U_n \leq x\} \\ & \leq \lim_{n \rightarrow \infty} P\{Z_n \leq x - c + \varepsilon\} + \lim_{n \rightarrow \infty} P\{|U_n - c| > \varepsilon\} \\ & = P\{Z \leq x - c + \varepsilon\} = F(x - c + \varepsilon) \end{aligned}$$

定理 1.5 设 $\{Z_n\}$ 为一随机变量序列, 且 $Z_n \xrightarrow{P} c$ (常数), 又函数 $g(\cdot)$ 在点 c 处连续, 则 $g(Z_n) \xrightarrow{P} g(c)$

例 1.6 设 $\{X_n\}$ 是独立同分布随机变量序列, 其均值为 μ , 方差为 $\sigma^2 < \infty$ 。模仿正态总体下的 t 统计量, 构造

$$t_n = \sqrt{n} (\bar{X} - \mu) S_n$$

常称 t_n 为 t 化统计量, 现求 t_n 的渐进分布。

由辛钦大数定律可知

$$\frac{1}{n} \sum_{i=1}^n (X_i - \mu)^2 \xrightarrow{P} \sigma^2, \quad \bar{X}_n = \sum_{i=1}^n X_i \xrightarrow{P} \mu$$

因此由 Slutsky 定理可知,

$$\frac{n}{n-1} \left[\frac{1}{n} \sum_{i=1}^n (X_i - \mu) - (\bar{X} - \mu)^2 \right] \xrightarrow{P} \sigma^2$$

另一方面, 由中心极限定理

$$Z_n = \sqrt{n} (\bar{X}_n - \mu) / \sigma \xrightarrow{L} N(0, 1)$$

最后, 由 Slutsky 定理可知 $t_n \xrightarrow{L} N(0, 1)$

定理 1.6 设 $\{a_n\}$ 为一趋于 ∞ 的序列, b 为常数, 并且对随机变量序列 $\{Z_n\}$ 有

$$a_n(Z_n - b) \xrightarrow{L} Z$$

有设 $g(\cdot)$ 为可微函数, 且 g' 在点 b 处连续, 则有

$$a_n[g(Z_n) - g(b)] \xrightarrow{L} g'(b)Z$$

例 1.7

1.5 充分统计量

2 点估计

2.1 基本概念

定义 2.1 (点估计) 设参数 θ , X 为样本, 用统计量 $\hat{\theta}(X)$ 作为未知参数 θ 的“猜测”称为点估计。

该估计的均方误差 MSE 为

$$\begin{aligned} \text{MSE}(\hat{\theta}) &= E(\hat{\theta}(X) - \theta)^2 = E\{[\hat{\theta}(X) - E(\hat{\theta}(X))] - [\theta - E(\hat{\theta}(X))]\}^2 \\ &= E[\hat{\theta}(X) - E(\hat{\theta}(X))]^2 + E[\theta - E(\hat{\theta}(X))]^2 \\ &= \text{var}(\hat{\theta}) + \text{bias}(\hat{\theta}) \end{aligned}$$

2.2 无偏估计及 UMVUE

2.2.1 无偏估计

定义 2.2 (无偏估计) 设 $(\mathcal{X}, \mathcal{B}, \{P_\theta, \theta \in \Theta\})$ 为可控参数统计结构, $g(\theta)$ 是未知参数, $X = (X_1, \dots, X_n)$ 是来自该统计结构的一个样本, 若用 $\hat{g}(X)$ 估计 $g(\theta)$, 且

$$E_\theta(\hat{g}(X)) = g(\theta), \forall \theta \in \Theta$$

则称 $\hat{g}(X)$ 为 $g(\theta)$ 的无偏估计。

评论 关于无偏估计, 我们有三点需要说明

1. 无偏估计不一定存在
2. 对可估参数, 无偏估计一般不唯一
3. 无偏估计并不一定是一个好估计

2.2.2 UMVUE

定义 2.3 设 $g(\theta)$ 是可估参数, $T(X) \in U_g$, 若对于 $\forall \phi(X) \in U_g$ 有

$$\text{var}_\theta T(X) \leq \text{var}_\theta \phi(X), \forall \theta \in \Theta$$

则称 $T(X)$ 是 $g(\theta)$ 的一致最小方差无偏估计 (UMVUE)。

引理 2.1 设 $S(X)$ 是分布族 $\{p_\theta, \theta \in \Theta\}$ 的充分统计量, $\phi(X)$ 是 $g(\theta)$ 的无偏估计, 令 $T(X) = E(\phi(X)|S(X))$, 则 $T(X)$ 也是 $g(\theta)$ 的无偏估计, 且 $\text{var } T(X) \leq \phi(X)$

评论 求 UMVUE 的方法

1. 寻找充分完备统计量的函数 $S(X)$, 使其属于 U_g
2. 任取 $\hat{g}(X) \in U_g$, 令 $T(X) = E(\hat{g}(X)|S(X))$

例 2.1 设 $X = (X_1, \dots, X_n)$ 是来自 $b(1, \theta), \theta \in (0, 1)$ 的一个样本, 由指数组性质知, $S(X) = \sum X_i$ 是充分完备统计量。

1. 对 θ , 因为 $E(S(X)) = n\theta$, 则 $\bar{X} = S(X)/n$ 是 θ 的无偏估计, 从而也是 θ 的 UMVUE。
2. 对于 $g(\theta) = \theta^k + (1 - \theta)^{n-k}, 0 \leq k \leq n$, 如何找 $g(\theta)$ 的 UMVUE?

对于 $g(\theta) = \theta^k + (1 - \theta)^{n-k}, 0 \leq k \leq n$, 先找一个 $g(\theta)$ 的无偏估计 $\phi(X)$ 。令

$$\phi_1(X) = \begin{cases} 1, & \sum_{i=1}^k X_i = k \\ 0, & \text{others} \end{cases}, \quad \phi_2(X) = \begin{cases} 1, & \sum_{i=k+1}^n X_i = 0 \\ 0, & \text{others} \end{cases}$$

又令 $\phi(X) = \phi_1(X) + \phi_2(X)$, 则

$$E(\phi(X)) = E(\phi_1(X)) + E(\phi_2(X)) = \theta^k + (1 - \theta)^{n-k} = g(\theta)$$

所以 $\phi(X) \in U_g$ 。故而 $T(X) = E(\phi(X)|S(X))$ 是 $g(\theta)$ 的 UMVUE。当 $k \leq s$ 时,

$$\begin{aligned} E(\phi_1(X)|S(X)) &= P(\phi_1(X) = 1|S(X) = s) \\ &= \frac{P(\phi_1(X) = 1, S(X) = s)}{P(S(X) = s)} = \frac{P(\sum_{i=1}^k X_i = k, \sum_{i=k+1}^n X_i = s - k)}{P(\sum_{i=1}^n X_i = s)} \\ &= \frac{\theta^k \cdot C_{n-k}^{s-k} \theta^{s-k} (1-\theta)^{n-s}}{C_n^s \theta^k (1-\theta)^{n-k}} = \frac{C_{n-k}^{s-k}}{C_n^s} \end{aligned}$$

当 $k \geq s$, $E(\phi_1(X)|S(X)) = 0$ 。

同理, 当 $k \geq s$ 时, $E(\phi_2(X)|S(X)) = \frac{C_k^s}{C_n^s}$

当 $k < s$ 时, $E(\phi_2(X)|S(X)) = 0$ 。

因此, $g(\theta)$ 的 UMVUE 为

$$T(X) = \begin{cases} \frac{C_{n-k}^{s-k}}{C_n^s} & k \leq s \\ \frac{C_k^s}{C_n^s} & k > s \end{cases}$$

例 2.2 设 X_1, \dots, X_n 是来自总体 X 的几何分布, 其概率分布为 $P_\theta(X = x) = (1-\theta)^x \theta, x = 0, 1, \dots$,。试求 θ 的 UMVUE。

对于 $\phi(X)$

$$\phi(X) = \begin{cases} 1, & X_1 = 0 \\ 0, & \text{others} \end{cases}$$

有 $E(\phi(X)) = P_\theta(X_1 = 1) = (1 - \theta)^0 \theta = \theta$ 。且 $\sum_{i=1}^n X_i \sim Nb(n; s, \theta)$ 服从负二项分布。因此,

$$\begin{aligned} E(\phi(X)|S(X)) &= P(\phi(X) = 1|S(X) = s) \\ &= \frac{P(\phi_1(X) = 1, S(X) = s)}{P(S(X) = s)} = \frac{P(X_1 = 0, \sum_{i=2}^n X_i = s)}{P(\sum_{i=1}^n X_i = s)} \\ &= \frac{\theta C_{s+n-2}^{n-2} \theta^{n-2} (1 - \theta)^s}{C_{s+n-1}^{n-1} \theta^{n-1} (1 - p)^s} = \frac{n - 1}{s + n - 1} \end{aligned}$$

例 2.3 设 X_1, \dots, X_n 独立同分布, 均服从区间 $(0, \theta), \theta > 0$ 上的均匀分布, 样本为 $X = (X_1, \dots, X_n)$ 。求参数 $g(\theta) = \theta^2$ 的 UMVUE。

首先, 我们知道 $X_{(n)}$ 是为一个完全充分统计量。

直接方法: 找到一个合适的 $X_{(n)}$ 的函数 $\phi(X_{(n)})$, 使得 $\phi(X_{(n)})$ 称为 $g(\theta) = \theta^2$ 的无偏估计, 即 $E_\theta(\phi(X_{(n)})) = \theta^2$ 。为此, 首先注意到 $X_{(n)}$ 的概率密度函数为

$$p(t; \theta) = \begin{cases} n \frac{t^{n-1}}{\theta^n}, & 0 < t < \theta \\ 0, & \text{others} \end{cases}$$

我们看一下其期望

$$E_{\theta} X_{(n)} = n \int_0^{\theta} n \frac{t^{n-1}}{\theta^n} t dx = \frac{n}{n+1} \theta$$
$$E_{\theta} X_{(n)}^2 = n \int_0^{\theta} n \frac{t^{n-1}}{\theta^n} t^2 dt = \frac{n}{n+2} \theta^2$$

于是我们就有 $E_{\theta} \left(\frac{n+2}{n} X_{(n)}^2 \right) = \theta^2$ 就得到 $\frac{n+2}{n} X_{(n)}^2$ 就是 θ^2 的无偏估计, 进而是 UMVUE。

条件期望法: 我们先找到 θ^2 的一个无偏估计, $E_{\theta} X_1^2 = \int_0^{\theta} t^2 \frac{1}{\theta} dt = \frac{\theta^2}{3}$, 课件 $3X_1^2$ 是 θ^2 的一个无偏估计, 进而求期望 $E_{\theta} [3X_1^2 | X_{(n)}]$ 。

$$\begin{aligned} E_{\theta} [3X_1^2 | X_{(n)} = t] &= \frac{1}{n} \cdot 3t^2 + \left(1 - \frac{1}{n}\right) \int_0^t 3u^2 \frac{1}{t} du \\ &= \frac{3t^2}{n} + \frac{n-1}{n} t^2 \\ &= \frac{n+2}{n} t^2 \end{aligned}$$

可见, $\frac{n+2}{n} X_{(n)}^2$ 为 θ^2 的 UMVUE

2.3 极大似然估计 (MLE)

极大似然估计在直观上可以这样解释: 使得出现所选样本最大概率的分布参数的估计。

定义 2.4 设 $X \sim f(x; \theta), \theta \in \Theta$, 把 $f(x; \theta)$ 是为 θ 的哈桑农户, 则称它为 X 关于 θ 的似然函数, $L(\theta, X) = \ln f(x; \theta) = L(\theta)$ 称为对数似然函数, 若 $\hat{\theta}$ 满足

$$f(x, \hat{\theta}(x)) = \max_{\theta \in \Theta} f(x; \theta)$$

称 $\hat{\theta}$ 为 θ 的极大似然估计。

例 2.4 设 X_1, \dots, X_n 是来自 $b(1, \theta)$ 的一个样本, $0 < \theta < 1$

$$l(\theta; x) = \left(\sum x_i \right) \ln \theta + \left(n - \sum x_i \right) \ln(1 - \theta)$$

由 $\frac{\partial l}{\partial \theta} = 0$ 知

$$\hat{\theta} = \bar{x}$$

评论 MLE 还有一个非常有吸引力的性质: 如果 $\hat{\theta}$ 是 θ 的 MLE, $g(\cdot)$ 为可测函数, 那么 $g(\hat{\theta})$ 也是 $g(\theta)$ 的 MLE。

对于多参数指数族 $p(x; \theta) = \exp\{\sum_{j=1}^k \theta_j T_j(x) + c(\theta) + d(x)\}$, 似然方程化为

$$\sum T_j(x_i) = -n \frac{\partial c(\theta)}{\partial \theta_j}$$

定理 2.2 (MLE 的相合性) 设 $\{p_\theta(x; \theta) : \theta \in \Theta\}$ 是可识别的, 且 $p_\theta(x; \theta)$ 关于 θ 可微, 则似然方程在 $n \rightarrow \infty$ 时, 以概率 1 有解, 且此解关于 θ 时相合的。

定理 2.3 (MLE 的渐进正态性) 在一系列正则条件下, 对于 $p(x; \theta)$ 的相合解 $\hat{\theta}_n$, 有

$$\sqrt{n}(\hat{\theta}_n - \theta_0) \xrightarrow{L} N(0, I^{-1}(\theta_0))$$

其中 θ_0 为真值。

3 假设检验

3.1 N-P 基本引理

定义 3.1 (最优势检验) 在检验问题 (θ_0, θ_1) 中, 若 ϕ 是一个 α 水平的检验, 若对任意一切 α 水平的检验 ϕ' , 均有 $E_{\theta_1}\phi(X) \geq E_{\theta_1}\phi'(X)$, 则称 ϕ 为最优势检验 MPT。

$$E_{\theta}\phi(X) = g_{\phi}(\theta) = \begin{cases} \alpha(\theta) & \theta \in \Theta_0 \\ 1 - \beta(\theta) & \theta \in \Theta_1 \end{cases}$$

定理 3.1 (N-P 引理) 对于问题 (θ_0, θ_1) , 设分布 $p_{\theta_0}, p_{\theta_1}$ 密度函数存在, 则 $\forall \alpha \in (0, 1)$

1. 存在一个 α 水平的检验 ϕ 及 $\lambda_0 > 0$ 使得 ϕ 形如

$$\phi(X) = \begin{cases} 1 & p(x; \theta_1) \geq \lambda_0 p(x; \theta_0) \\ 0 & p(x; \theta_1) < \lambda_0 p(x; \theta_0) \end{cases}$$

且 $E_{\theta_0}\phi(X) = \alpha$

2. 此 $\phi(X)$ 是一个 MPT

3. 反之, 如果 $\phi(X)$ 是水平为 α 的 MPT, 则一定存在常数 $\lambda_0 \geq 0$, 使得 $\phi(X)$ 满足 1

例 3.1 设 X_1, X_2, \dots, X_n 来自两点分布 $b(1, \theta)$ 的样本, 对于假设问题 $H_0: \theta = \frac{1}{2}, H_1: \theta = \theta_1 (\theta_1 > \frac{1}{2})$, 试求其最优势检验

似然比:

$$\lambda(X) = \frac{\prod_{i=1}^n p(x_i; \theta_1)}{\prod_{i=1}^n p(x_i; \theta_0)} = 2^n \left(\frac{\theta_1}{1 - \theta_1} \right)^{\sum_{i=1}^n x_i} (1 - \theta_1)^n$$

原假设成立条件下, $T = \sum_{i=1}^n X_i \sim b(n, \frac{1}{2})$, 且 $\lambda(X)$ 是关于 T 递增的, 那么 $\{\lambda \geq k\} = \{T \geq c\}$

$$\phi(X) = \begin{cases} 1 & T > c \\ r & T = c \\ 0 & T < c \end{cases}$$

$$\alpha = E_{\theta_0} \phi(X) = P\{T > c\} + rP(T = c)$$

$$\text{得到 } c = u_{1-\alpha_1}, r = \frac{\alpha - \alpha_1}{G(c - 0) - G(c)} = \frac{\alpha - \alpha_1}{F(c) - F(c - 0)}$$

例 3.2 设 X_1, X_2, \dots, X_n 来自两点分布 $N(\mu, 1)$ 的样本, 对于假设问题 $H_0: \mu = 0, H_1: \mu = \mu_1 (\mu_1 > 0)$, 试求其最优势检验

似然比:

$$\lambda(X) = \frac{\prod_{i=1}^n p(x_i; \theta_1)}{\prod_{i=1}^n p(x_i; \theta_0)} = \exp\left\{-\frac{1}{2}n\mu_1^2 + \sum_{i=1}^n x_i \mu_1\right\}$$

原假设成立条件下, $T = \bar{X} \sim N(0, \frac{1}{n})$, 且 $\lambda(X)$ 是关于 T 递增的, 那么 $\{\lambda \geq k\} = \{T \geq c\}$

$$\phi(X) = \begin{cases} 1 & T \geq c \\ 0 & T < c \end{cases}$$

$$\alpha = E_{\theta_0} \phi(X) = P\{T \geq c\}$$

得到 $c = \frac{u_{1-\alpha}}{\sqrt{n}}$

例 3.3 设 $X = (X_1, \dots, X_n)$ 是来自均匀分布组 $\{R(0, \theta) : \theta > 0\}$ 的样本, 考虑如下检验问题:
 $H_0 : \theta = 1, H_1 : \theta_1 = \theta_1 (\theta_1 > 1)$, 取水平为 $\alpha (0 < \alpha < 1)$ 。构造似然比统计量

$$\lambda(X) = \frac{\prod_{i=1}^n p(x_i; \theta_1)}{\prod_{i=1}^n p(x_i; \theta_0)} = \begin{cases} \theta_1^{-n} & 0 < x_{(n)} < 1 \\ \infty & 1 \leq x_{(n)} \leq \theta_1 \end{cases}$$

$\lambda(X)$ 为退化分布

取非随机化检验:

$$\phi(x) = \begin{cases} 1 & c \leq x_{(n)} < \theta_1 \\ 0 & 0 < x_{(n)} < c \end{cases}$$

原假设 H_0 成立时, $T = X_{(n)}$ 的密度函数为 $nt^{n-1}, (1 < t < 1)$, 故由 $E_{\theta_0} \pi(X) = \alpha$ 得 $c = \sqrt[n]{1-\alpha}$

例 3.4 设 $X = (X_1, \dots, X_n)$ 是来自均匀分布组 $\{R(0, \theta) : \theta > 0\}$ 的样本, 考虑如下检验问题:
 $H_0 : \theta = 1, H_1 : \theta_1 = \theta_1 (\theta_1 < 1)$, 取水平为 $\alpha (0 < \alpha < 1)$ 。构造似然比统计量

$$\lambda(X) = \frac{\prod_{i=1}^n p(x_i; \theta_1)}{\prod_{i=1}^n p(x_i; \theta_0)} = \begin{cases} \theta_1^{-n} & 0 < x_{(n)} < \theta_1 \\ 0 & \theta_1 \leq x_{(n)} < 1 \end{cases}$$

$\lambda(X)$ 为退化分布

取非随机化检验:

$$\phi(x) = \begin{cases} 1 & 0 \leq x_{(n)} \leq c \\ 0 & c < x_{(n)} < \theta_1 \end{cases}$$

原假设 H_0 成立时, $T = X_{(n)}$ 的密度函数为 nt^{n-1} , $(1 < t < 1)$, 故由 $E_{\theta_0}\phi(X) = \alpha$ 得 $c = \sqrt[n]{\alpha}$

例 3.5 设 $X_1, \dots, X_n \sim U(\theta, 1)$ 的样本, 考虑如下检验问题: $H_0: \theta = 0, H_1: \theta_1 = \theta_1 (\theta_1 < 0)$, 取水平为 $\alpha (0 < \alpha < 1)$, 试求其 MPT。

构造似然比统计量

$$\lambda(X) = \frac{\prod_{i=1}^n p(x_i; \theta_1)}{\prod_{i=1}^n p(x_i; \theta_0)} = \begin{cases} (1 - \theta_1)^{-n} & 0 < x_{(1)} < 1 \\ \infty & \theta_1 \leq x_{(1)} \leq 0 \end{cases}$$

$\lambda(X)$ 为退化分布

取非随机化检验:

$$\phi(x) = \begin{cases} 1 & 0 \leq x_{(1)} \leq c \\ 0 & c < x_{(n)} < 1 \end{cases}$$

原假设 H_0 成立时, $T = X_{(1)}$ 的密度函数为 $n(1-t)^{n-1}$, $(1 < t < 1)$, 故由 $E_{\theta_0}\phi(X) = \alpha$ 得 $c = 1 - \sqrt[n]{1 - \alpha}$

例 3.6 电话交换台单位时间内接到的呼唤次数服从 Poisson 分布 $P(\lambda)$, $\lambda > 0$. λ 为单位时间内接到的平均呼唤次数. 设 $x = (x_1, \dots, x_{10})$ 是该电话交换台的 10 次记录. 考虑假设检验问题: 原假设 $H_0: \lambda \geq 1$ 对备择假设 $H_1: \lambda < 1$. 取水平为 $\alpha = 0.05$.

解：取检验统计量为 λ 的完备充分统计量 $T(x) = \sum_{i=1}^n x_i$.

对于 $H_0: \lambda \geq 1$ 和 $H_1: \lambda < 1$ ，其拒绝域为 $W = \{x: \sum_{i=1}^n x_i \leq c\}$,

检验函数为：

$$\Phi(x) = \begin{cases} 1, & T(x) < c, \\ r, & T(x) = c, \\ 0, & T(x) > c. \end{cases}$$

势函数为：

$$g(\lambda) = P_{\lambda}(x \in W) = \sum_{k=0}^{c-1} \frac{(n\lambda)^k}{k!} e^{-n\lambda} + r \frac{(n\lambda)^c}{c!} e^{-n\lambda}$$

,

当 $n = 10$ ， $\lambda = 1$ 时，由

$$\begin{cases} \sum_{k=0}^4 \frac{(n\lambda)^k}{k!} e^{(-n\lambda)} = 0.02921 \\ \sum_{k=0}^5 \frac{(n\lambda)^k}{k!} e^{(-n\lambda)} = 0.06704 \end{cases}$$

得 $c=5$.

即 $\sum_{k=0}^4 \frac{(n\lambda)^k e^{(-n\lambda)}}{k!} + r \frac{(n\lambda)^c}{c!} e^{-n\lambda} = 0.05$ ，解得 $r = 0.5496$. 故检验函数为：

$$\Phi(x) = \begin{cases} 1, & T(x) < c, \\ 0.5496, & T(x) = c, \\ 0, & T(x) > c. \end{cases}$$

例 3.7 设 $X = (X_1, \dots, X_n)$ 是来自正态分布族 $\{N(0, \sigma^2) : 0 < \sigma^2 < \infty\}$ 的样本, 考虑原假设 $H_0 : \sigma^2 = 1$ 对备择假设 $H_1 : \sigma^2 = \sigma_1^2 (\sigma_1^2 > 1)$ 的检验问题, 取水平为 $\alpha (0 < \alpha < 1)$, 试求其 MPT.

解:

密度函数: $p(x; \sigma^2) = (2\pi)^{-1/2} \sigma^{-1} \exp\{x^2/(2\sigma^2)\}$,

似然函数: $L(x; \sigma^2) = (2\pi)^{-n/2} \sigma^{-n} \exp\{-\sum_{i=1}^n x_i^2/(2\sigma^2)\}$,

由因子分解定理知, $T(x) = \sum_{i=1}^n x_i^2$ 为该分布的完备充分统计量.

构造似然比统计量:

$$\begin{aligned} \lambda(x) &= \frac{\prod_{i=1}^n p(x_i; \sigma_1^2)}{\prod_{i=1}^n p(x_i; \sigma_0^2)} = \frac{\sigma_0^n}{\sigma_1^n} \exp\left\{\sum_{i=1}^n x_i^2 \left(\frac{1}{2\sigma_0^2} - \frac{1}{2\sigma_1^2}\right)\right\} \\ &= \frac{\sigma_0^n}{\sigma_1^n} \exp\left\{T(x) \left(\frac{1}{2\sigma_0^2} - \frac{1}{2\sigma_1^2}\right)\right\}, \end{aligned}$$

$\lambda(x)$ 关于 $T(x)$ 严格单调上升, 根据 N-P 基本引理, MPT 的拒绝域形式为 $W = \{x : T(x) = \sum_{i=1}^n x_i^2 \geq c\}$.

当 H_0 成立时, $T \sim \chi^2(n)$, 所以对给定的水平 α , $c = \chi_{1-\alpha}^2(n)$.

MPT 检验仅与水平 α 有关, 而与 σ_1^2 的具体数值无关, 只要求 $\sigma_1^2 > 1$ 就行了.

故 MPT 为：

$$\phi(x) = \begin{cases} 1, & T \geq \chi^2_{1-\alpha}(n), \\ 0, & T < \chi^2_{1-\alpha}(n). \end{cases}$$